

황 선 정 | Seonjeong Hwang

Tel: 010-2323-5608 / Email: seonjeongh@postech.ac.kr

목차

I. 논문 (♣: 1 저자)

1. A Multi-Agent Framework for Feature-Constrained Difficulty Control in Reading Comprehension Item Generation*
2. Why Do Multilingual Reasoning Gaps Emerge in Reasoning Language Models?
3. Difficulty-Controllable Cloze Question Distractor Generation
4. Can LLMs Estimate Cognitive Complexity of Reading Comprehension Items?*
5. KOBLEX: Open Legal Question Answering with Multi-hop Reasoning
6. MiLQ: Benchmarking IR Models for Bilingual Web Search with Mixed Language Queries
7. Cross-lingual Transfer for Automatic Question Generation by Learning Interrogative Structures in Target Languages*
8. Cross-lingual Back-Parsing: Utterance Synthesis from Meaning Representation for Zero-Resource Semantic Parsing
9. Explainable Multi-hop Question Generation: An End-to-End Approach without Intermediate Question Labeling*
10. Multi-Type Conversational Question-Answer Generation with Closed-ended and Unanswerable Questions*
11. Conversational QA Dataset Generation with Answer Revision*

II. 산학협력 프로젝트

1. Whale UBT 자동 채점 및 자동 출제 시스템 개발을 위한 연구
2. 문항 유사도 분석 및 한국어능력평가(TOPIK) 자동 생성 알고리즘 연구
3. 고성능 비지도 및 자기지도 대화 시스템 개발

I. 논문

1. A Multi-Agent Framework for Feature-Constrained Difficulty Control in Reading Comprehension Item Generation*

황선정, 서준, 김형훈, 이근배

ACL 2026 - Main Conference (<https://arxiv.org/pdf/2605.19316>)

연구 목적

학습용 문항의 난이도를 조절할 때 지문의 길이, 어휘 수준, 추론 복잡도 등의 문항 특징(item features)을 제어하는 방식의 효과가 입증되었음. 하지만 단일 LLM prompting 방식은 세부 제약 사항 미준수 및 난이도 조절의 불확실성 문제가 존재함. 본 연구는 대규모 학습자 응답 데이터가 부재한 상황에서도 정교하고 일관된 난이도의 독해 문항을 생성할 수 있는 프레임워크 구축을 목표로 함.

접근 방법 및 결과

LLM 기반의 Role-specialized agent 들과 evaluator 들로 구성된 멀티 에이전트 프레임워크인 MAFIG 를 제안함. 본 프레임워크는 에이전트들 간의 협업 및 반복적인 문항 개선을 통해 multi-dimensional constraints 를 준수하는 독해 문항을 생성함. 또한 교육학적 원리를 반영한 difficulty-calibrated feature constraint sequence 를 설계하여, 생성된 문항 간의 명확하고 일관된 난이도 위계를 보장함. 실험 결과, GPT-5 기반의 prompting-based baseline 대비 constraint satisfaction 및 difficulty calibration 면에서 우수한 성능을 기록함.

본인 기여도

1 저자. 문제 정의, 관련 연구 탐색, 방법론 설계 및 구현, 실험 및 분석, 논문 작성 등 전 과정을 수행.

초록

Recent studies in difficulty-controlled reading comprehension item generation have leveraged large language models (LLMs) to produce items by adjusting difficulty-related features. However, existing methods typically rely on a single-agent prompting approach, which often fails to consistently satisfy specified feature constraints, resulting in items that deviate from the target difficulty level. To address this limitation, we introduce MAFIG, a Multi-agent Framework for Feature-constrained Item Generation, where multiple LLM agents and feature-specific evaluators collaborate to generate and iteratively revise items based on intended constraints. Furthermore, to verify the efficacy of MAFIG in difficulty control, we propose a method for constructing a sequence of feature constraint sets that yield items with monotonically increasing difficulty. Experimental results demonstrate that MAFIG generates items that adhere to target constraints at a significantly higher rate than baselines, achieving robust difficulty control through this difficulty-calibrated constraint sequence.

I. 논문

2. Why Do Multilingual Reasoning Gaps Emerge in Reasoning Language Models?

강덕형, 황선정, 김대희, 김형훈, 이근배

ACL 2026 – Findings (<https://arxiv.org/pdf/2510.27269>)

연구 목적

Qwen3, GPT-oss 등 Reasoning Language Models(RLMs)에서 발생하는 high-resource 언어와 low-resource 언어 간의 multilingual reasoning gap 의 근본적인 원인을 규명하고자 함.

접근 방법 및 결과

모델의 추론 과정을 input understanding, reasoning, response generation 의 3 단계로 정형화하고, 각 단계에서의 실패가 최종 성능에 미치는 영향을 stage-wise attribution analysis 를 통해 수치적으로 분석함. 결과적으로 low-resource 언어에서 발생하는 추론 오류의 핵심 원인이 understanding 단계에서의 실패임을 입증함. 또한 understanding 실패를 자동으로 탐지하기 위해 supervised detector 등 다양한 방법론들을 적용하여 understanding 실패 신호의 탐지 가능성을 확인했으며, 실패가 감지될 때만 선별적으로 번역을 수행하는 Selective Translation 기법의 효과를 확인함. 해당 기법을 통해 약 20%의 입력만 번역하고도 full translation 에 근접한 성능 향상을 달성하며 추론 효율성과 정확도를 동시에 확보함.

본인 기여도

공저자. 방법론 및 실험 설계, 논문 작성 등 참여.

초록

Reasoning language models (RLMs) achieve strong performance on complex reasoning tasks, yet they still exhibit a multilingual reasoning gap, performing better in high-resource languages than in low-resource ones. While recent efforts have been made to address this gap, its underlying causes remain largely unexplored. In this work, we show that this gap primarily stems from failures in language understanding—specifically, the model’s inability to translate multilingual inputs into the language dominating its reasoning traces (typically English). As identifying understanding failures can enable targeted mitigation of the gap, we evaluate a range of detection methods and find that understanding failures are detectable to a meaningful extent, with supervised approaches performing best. Building on this, we propose Selective Translation, a strategy that incorporates an English translation into the initial reasoning trace only when an understanding failure is detected. Experimental results using Qwen3-4B show that Selective Translation substantially bridges the multilingual reasoning gap, achieving near full-translation performance while translating only about 20% of inputs. Together, our results show that failures in language understanding are the primary driver of the multilingual reasoning gap and can be detected and selectively mitigated, clarifying its origin and suggesting a path toward more equitable multilingual reasoning.

I. 논문

3. Difficulty-Controllable Cloze Question Distractor Generation

강석훈, 전예진, 황선정, 이근배

ACL 2026 - Main Conference (<https://arxiv.org/pdf/2511.01526>)

연구 목적

Multiple-choice cloze question 생성 시 난이도가 조절된 고품질의 오답 선택지를 생성하는 데 따르는 한계를 해결하고자 함. 특히 난이도가 라벨링된 데이터셋의 부족과 기존 모델들의 난이도 제어 성능 저하 문제를 극복하고자 함.

접근 방법 및 결과

Information restriction 기반의 two-way data augmentation 파이프라인을 설계하여 난이도별로 라벨링된 대규모 오답 데이터셋을 구축함. 이를 바탕으로 auxiliary task 가 포함된 multitask learning 을 적용해 선택지 생성 모델이 정답과 오답의 차이를 명확히 구분하고 의도한 난이도(Easy/Hard)를 정확히 반영하도록 sLLM 을 파인튜닝함. 실험 결과, GPT-4o 기반 prompting 방법론 대비 difficulty alignment 및 invalid distractor ratio 면에서 월등한 성능을 입증함.

본인 기여도

공저자. 실험 설계 개선, 논문 작성 등 참여.

초록

Multiple-choice cloze questions are commonly used to assess linguistic proficiency and comprehension. However, generating high-quality distractors remains challenging, as existing methods often lack adaptability and control over difficulty levels, and the absence of difficulty-annotated datasets further hinders progress. To address these issues, we propose a novel framework for generating distractors with controllable difficulty by leveraging both data augmentation and a multitask learning strategy. First, to create a high-quality, difficulty-annotated dataset, we introduce a two-way distractor generation process in order to produce diverse and plausible distractors. These candidates are subsequently refined through filtering and then categorized by difficulty using an ensemble QA system. Second, this newly created dataset is leveraged to train a difficulty-controllable generation model via multitask learning. The framework includes carefully designed auxiliary tasks that enhance the model's semantic understanding of distractors and its ability to estimate their difficulty. Experimental results demonstrate that our method generates high-quality distractors across difficulty levels and substantially outperforms GPT-4o in aligning distractor difficulty with human perception.

I. 논문

4. Can LLMs Estimate Cognitive Complexity of Reading Comprehension Items?*

황선정, 김형훈, 이근배

ACL 2026 - Main Conference (<https://arxiv.org/pdf/2510.25064>)

연구 목적

지문 내에서의 Evidence Scope(근거 범위) 및 지문과 선택지 간의 Transformation Level(변형 정도) 등 인지적 복잡도 결정하는 특성들은 독해 문항의 난이도를 결정하는 핵심 요소로 알려져 있음. 지문 길이, 어휘 난이도 등의 표면적 특성들과 달리, 분석 과정에서 전문가의 판단에 의존해온 고차원적 인지 요인을 LLM의 추론 능력을 통해 자동 측정할 수 있는지 확인하고자 함.

접근 방법 및 결과

인지적 복잡도를 기준으로 문항을 라벨링한 데이터셋 ReCo를 구축하여 8종의 LLM을 대상으로 복잡도 측정 능력을 평가했으며, 최신 오픈소스 모델들이 GPT-4o와 대등하거나 이를 상회하는 수준으로 인지적 요인을 근사할 수 있음을 입증함. 다만, 모델이 문항의 정답을 맞히더라도 생성한 풀이 과정에 포함된 인지적 특성을 명시적으로 식별하는 데에는 한계가 있음을 확인함.

본인 기여도

1 저자. 문제 정의, 관련 연구 탐색, 어노테이션 과정 설계 및 진행, 실험 및 분석, 논문 작성 등 전 과정을 수행.

초록

Estimating the cognitive complexity of reading comprehension (RC) items is crucial for assessing item difficulty before it is administered to learners. Unlike syntactic and semantic features, such as passage length or semantic similarity between options, cognitive features that arise during answer reasoning are not readily extractable using existing NLP tools and have traditionally relied on human annotation. In this study, we examine whether large language models (LLMs) can estimate the cognitive complexity of RC items by focusing on two dimensions—Evidence Scope and Transformation Level—that indicate the degree of cognitive burden involved in reasoning about the answer. Our experimental results demonstrate that LLMs can approximate the cognitive complexity of items, indicating their potential as tools for prior difficulty analysis. Further analysis reveals a gap between LLMs' reasoning ability and their metacognitive awareness: even when they produce correct answers, they sometimes fail to correctly identify the features underlying their own reasoning process.

I. 논문

5. KOBLEX: Open Legal Question Answering with Multi-hop Reasoning

이지형*, 김대희*, 황선정, 김형훈, 이근배

EMNLP 2025 – Main Conference (<https://aclanthology.org/2025.emnlp-main.200>)

연구 목적

Hallucination 위험이 크고 복잡한 법률 도메인에서, 조문에 근거한 개방형 QA 및 multi-hop reasoning 능력을 정밀하게 평가하고 향상시키고자 함. 단순 검색을 넘어 법률 전문가 수준의 지식 기반 조문 해석과 multi-hop reasoning 능력을 확인할 수 있는 한국어-영어 bilingual 벤치마크 및 고성능 QA 프레임워크 구축을 목표로 함.

접근 방법 및 결과

관련 조문을 탐색해 multi-hop QA 쌍을 생성하는 파이프라인을 설계함. 또한 합성 데이터에 대한 전문가의 교차 검증 및 필터링을 통해 226 개의 고품질 데이터로 구성된 bilingual 벤치마크인 KOBLEX 를 구축함. 한편으로, LLM 의 내부 지식을 활용해 가상의 조문을 생성함으로써 검색 효율을 높이는 ParSeR 방법론과, 법률적 충실도를 측정하는 L-FEval metric 을 제안함. 실험 결과, KOBLEX 벤치마크에서 ParSeR 가 기존 RAG 기반 방법론 대비 조문 검색 및 답변 품질 면에서 SOTA 성능을 달성함.

본인 기여도

공저자. 데이터 생성 파이프라인 및 ParSeR 방법론 설계, 전문가 평가 진행, 논문 작성 등 참여

초록

Large Language Models (LLM) have achieved remarkable performances in general domains and are now extending into the expert domain of law. Several benchmarks have been proposed to evaluate LLMs' legal capabilities. However, these benchmarks fail to evaluate open-ended and provision-grounded Question Answering (QA). To address this, we introduce a Korean Benchmark for Legal EXplainable QA (KoBLEX), designed to evaluate provision-grounded, multi-hop legal reasoning. KoBLEX includes 226 scenario-based QA instances and their supporting provisions, created using a hybrid LLM-human expert pipeline. We also propose a method called Parametric provision-guided Selection Retrieval (ParSeR), which uses LLM-generated parametric provisions to guide legally grounded and reliable answers. ParSeR facilitates multi-hop reasoning on complex legal questions by generating parametric provisions and employing a three-stage sequential retrieval process. Furthermore, to better evaluate the legal fidelity of the generated answers, we propose Legal Fidelity Evaluation (LF-Eval). LF-Eval is an automatic metric that jointly considers the question, answer, and supporting provisions and shows a high correlation with human judgments. Experimental results show that ParSeR consistently outperforms strong baselines, achieving the best results across multiple LLMs. Notably, compared to standard retrieval with GPT-4o, ParSeR achieves +37.91 higher F1 and +30.81 higher LF-Eval. Further analyses reveal that ParSeR efficiently delivers consistent performance across reasoning depths, with ablations confirming the effectiveness of ParSeR.

I. 논문

6. MiLQ: Benchmarking IR Models for Bilingual Web Search with Mixed Language Queries (Short Paper)

김중휘, 강덕형, **황선정**, 김윤수, 옥정슬, 이근배

EMNLP 2025 - Main Conference (<https://aclanthology.org/2025.emnlp-main.1153>)

연구 목적

이중 언어 사용자들이 한 문장 내에서 여러 언어를 혼용하는 code-switching 현상이 실제 HCI 환경에서 빈번하게 발생함에도 불구하고, 이러한 형태의 질의에 대한 모델 성능을 평가할 수 있는 Information Retrieval(IR) 벤치마크가 부재함. 기존의 검색 모델들이 실제 사용자가 생성한 mixed-language query 를 효과적으로 처리할 수 있는지 확인하고, code-switching 전략이 검색 효율성에 미치는 영향을 분석할 수 있는 기반을 마련하고자 함.

접근 방법 및 결과

실제 이중 언어 사용자들이 작성한 최초의 mixed-language query 벤치마크인 MiLQ 를 구축하여 공개하고, 기존 다국어 IR 모델들의 mixed-language query IR 성능에 대한 baseline 을 제시함. 실험을 통해 의도적인 영어 용어 혼용이 영문 문서 검색 성능을 유의미하게 향상시키는 효과적인 전략임을 확인했으며, 토큰 단위 분석을 통해 언어 혼용이 검색 결과에 기여하는 구체적인 메커니즘을 밝힘.

본인 기여도

공저자. 실험 설계 및 결과 분석에 대한 토론, 논문 작성 등 참여

초록

Despite bilingual speakers frequently using mixed-language queries in web searches, Information Retrieval (IR) research on them remains scarce. To address this, we introduce MiLQ, Mixed-Language Query test set, the first public benchmark of mixed-language queries, qualified as realistic and relatively preferred. Experiments show that multilingual IR models perform moderately on MiLQ and inconsistently across native, English, and mixed-language queries, also suggesting code-switched training data's potential for robust IR models handling such queries. Meanwhile, intentional English mixing in queries proves an effective strategy for bilinguals searching English documents, which our analysis attributes to enhanced token matching compared to native queries.

I. 논문

7. Cross-lingual Transfer for Automatic Question Generation by Learning Interrogative Structures in Target Languages*

황선정, 김윤수, 이근배

EMNLP 2024 - Main Conference (<https://aclanthology.org/2024.emnlp-main.186>)

연구 목적

다양한 유형의 영어 QA 데이터가 공개 되어있는 반면, 타언어에서는 데이터 부족 문제를 겪고 있음. 타언어의 데이터를 구축하여 모델을 훈련시키거나 고비용의 다국어 LLM 을 활용하지 않고도, 영어 데이터만으로 학습된 모델을 다양한 언어의 QA 데이터 생성에 활용할 수 있도록 하는 효율적인 cross-lingual transfer 방법론을 찾고자 함.

접근 방법 및 결과

질문의 맥락 텍스트와 목표 답변을 기반으로 생성될 질문의 의문사를 예측하는 모델과, 텍스트, 답안, 그리고 예측된 의문사에 해당되는 소량의 question exemplar 를 입력 받아 질문을 생성하는 모델로 구성된 QuIST 프레임워크를 제안함. 질문 생성 모델은 주어진 텍스트와 답변에 부합하는 질문의 semantic 을 구성하면서도, question exemplar 의 통사 구조를 반영하여 질문을 생성하도록 훈련됨. 이러한 훈련 방식을 통해 타언어에 대해서도 해당 언어의 question exemplar 만을 참조하여 의미적·통사적으로 높은 품질의 질문을 생성할 수 있으며, 특히 훈련 단계에서는 영어 데이터만을 활용함으로써 높은 language scalability 를 확보함. 실험 결과, mBERT 와 mT5 기반의 QuIST 가 GPT-3.5-turbo 에 상응하는 생성 품질을 달성함. 또한 다국어 QA 모델 학습을 위한 데이터 증강 측면에서도 기존 방식보다 높은 실용성을 입증함.

본인 기여도

1 저자. 문제 정의, 관련 연구 탐색, 방법론 설계 및 구현, 실험 및 분석, 논문 작성 등 전 과정을 수행.

초록

Automatic question generation (QG) serves a wide range of purposes, such as augmenting question-answering (QA) corpora, enhancing chatbot systems, and developing educational materials. Despite its importance, most existing datasets predominantly focus on English, resulting in a considerable gap in data availability for other languages. Cross-lingual transfer for QG (XLT-QG) addresses this limitation by allowing models trained on high-resource language datasets to generate questions in low-resource languages. In this paper, we propose a simple and efficient XLT-QG method that operates without the need for monolingual, parallel, or labeled data in the target language, utilizing a small language model. Our model, trained solely on English QA datasets, learns interrogative structures from a limited set of question exemplars, which are then applied to generate questions in the target language. Experimental results show that our method outperforms several XLT-QG baselines and achieves performance comparable to GPT-3.5-turbo across different languages. Additionally, the synthetic data generated by our model proves beneficial for training multilingual QA models. With significantly fewer parameters than large language models and without requiring additional training for target languages, our approach offers an effective solution for QG and QA tasks across various languages.

I. 논문

8. Cross-lingual Back-Parsing: Utterance Synthesis from Meaning Representation for Zero-Resource Semantic Parsing

강덕형, 황선정, 김윤수, 이근배

EMNLP 2024 - Main Conference (<https://aclanthology.org/2024.emnlp-main.792>)

연구 목적

자연어 질의를 meaning representation(SQL, Python 코드 등)으로 변환하는 Semantic Parsing은 영어를 제외한 타언어의 학습 데이터 확보에 큰 비용이 발생함. 번역기나 병렬 코퍼스 같은 외부 리소스가 없는 zero-resource 환경에서도 영문 meaning representation 으로부터 목표 언어의 utterance 를 생성하여 모델의 cross-lingual transfer 능력을 향상시킬 수 있는 데이터 증강 방법론을 찾고자 함.

접근 방법 및 결과

목표 언어의 utterance 를 합성하는 생성기와, 품질 필터링 메커니즘으로 구성된 cross-lingual back-parsing(CBP) 방법론을 제안함. 다국어 PLM 의 hidden representation 에서 언어 식별 정보를 분리할 수 있다는 점에서 착안하여, 목표 언어의 단일 언어 코퍼스만으로 훈련 가능한 source-switched denoising objective 를 설계하고 이를 통해 language-specific adapter 를 학습시킴. 실험 결과, 제안된 모델은 Mschema2QA 및 Xspider 벤치마크에서 SOTA 대비 향상된 성능을 보였으며, 특히 번역기 기반 데이터 증강 기법이 적용된 모델보다 Mschema2QA 에서 더 높은 정확도를 기록함.

본인 기여도

공저자. 방법론 설계 및 아키텍처 구현, 논문 작성 등 참여

초록

Recent efforts have aimed to utilize multilingual pretrained language models (mPLMs) to extend semantic parsing (SP) across multiple languages without requiring extensive annotations. However, achieving zero-shot cross-lingual transfer for SP remains challenging, leading to a performance gap between source and target languages. In this study, we propose Cross-Lingual Back-Parsing (CBP), a novel data augmentation methodology designed to enhance cross-lingual transfer for SP. Leveraging the representation geometry of the mPLMs, CBP synthesizes target language utterances from source meaning representations. Our methodology effectively performs cross-lingual data augmentation in challenging zero-resource settings, by utilizing only labeled data in the source language and monolingual corpora. Extensive experiments on two cross-language SP benchmarks (Mschema2QA and Xspider) demonstrate that CBP brings substantial gains in the target language. Further analysis of the synthesized utterances shows that our method successfully generates target language utterances with high slot value alignment rates while preserving semantic integrity.

9. Explainable Multi-hop Question Generation: An End-to-End Approach without Intermediate Question Labeling*

황선정, 김윤수, 이근배

LREC-COLING 2024 - Main Conference (<https://aclanthology.org/2024.lrec-main.599>)

연구 목적

여러 문서에 흩어진 정보를 기반으로 한 복잡한 추론을 요구하는 multi-hop 질문을 자동으로 생성하는 설명 가능한 방법론을 개발하고자 함. 기존의 end-to-end 구조의 방법론들은 참조 문서가 늘어날수록 질문의 논리적 일관성이 저하되는 한계가 있었음. 또한 step-by-step rewriting 은 논리성과 설명 가능성을 높이는 효과적인 접근법이지만, 중간 단계 복잡도의 질문 라벨링이 필수적이라는 한계점이 있었음. 이를 해결하기 위해 중간 단계 질문에 대한 라벨링 없이도 single-hop question 을 점진적으로 확장하여 복잡도를 높이는 multi-hop question generation(QG) 프레임워크를 구축하고자 함.

접근 방법 및 결과

Transformer 아키텍처를 recurrent neural network 구조로 수정한 end-to-end question rewriting (E2EQR) 모델을 제안함. 생성된 질문을 다음 단계의 입력으로 사용하는 일반적인 방법 대신, 질문의 디코딩 과정에서 계산된 hidden states 를 후속 time-step 으로 전달함으로써 내부적으로 점진적인 question rewriting 이 수행될 수 있도록 함. 본 아키텍처는 중간 단계 복잡도의 ground truth 질문 없이도 end-to-end 학습이 가능함. 실험을 통해 3-hop 이상의 높은 복잡도 질문 생성 시나리오에서 논리적 정교함이 뛰어난 SOTA 급 성능을 입증하고, 생성된 데이터가 QA 모델 성능 향상을 위한 데이터 증강에도 효과적임을 확인함.

본인 기여도

1 저자. 문제 정의, 관련 연구 탐색, 방법론 설계 및 구현, 실험 및 분석, 논문 작성 등 전 과정을 수행.

초록

In response to the increasing use of interactive artificial intelligence, the demand for the capacity to handle complex questions has increased. Multi-hop question generation aims to generate complex questions that requires multi-step reasoning over several documents. Previous studies have predominantly utilized end-to-end models, wherein questions are decoded based on the representation of context documents. However, these approaches lack the ability to explain the reasoning process behind the generated multi-hop questions. Additionally, the question rewriting approach, which incrementally increases the question complexity, also has limitations due to the requirement of labeling data for intermediate-stage questions. In this paper, we introduce an end-to-end question rewriting model that increases question complexity through sequential rewriting. The proposed model has the advantage of training with only the final multi-hop questions, without intermediate questions. Experimental results demonstrate the effectiveness of our model in generating complex questions, particularly 3- and 4-hop questions, which are appropriately paired with input answers. We also prove that our model logically and incrementally increases the complexity of questions, and the generated multi-hop questions are also beneficial for training question answering models.

I. 논문

10. Multi-Type Conversational Question-Answer Generation with Closed-ended and Unanswerable Questions* (Short Paper)

황선정, 김윤수, 이근배

AACL-IJCNLP 2022 (<https://aclanthology.org/2022.aacl-short.22>)

연구 목적

대화형 질의응답(CQA) 시스템 구축을 위한 데이터 제작 시 발생하는 높은 비용 문제를 해결하고자 함. 기존의 자동 생성 프레임워크는 주로 open-ended 질문 생성에 국한되어 있어, 실제 대화 환경에서 빈번하게 발생하는 closed-ended (예: yes/no) 질문이나 unanswerable 질문을 처리하는데 한계가 있음. 이를 극복하여 보다 실제적이고 다양한 문항 유형을 포함하는 CQA 데이터 합성 프레임워크를 구축하고자 함.

접근 방법 및 결과

Open-ended, closed-ended, 그리고 unanswerable 대화형 질문을 모두 합성할 수 있는 MultiCQAG 프레임워크를 제안함. 기존 open-ended CQA 데이터 생성 프레임워크에 closed-ended QA pair 생성 플로우를 통합하고, 부적절한 질의응답 쌍을 필터링하는 동시에 unanswerable 질문을 수집하는 hierarchical answerability classification 알고리즘을 설계함. 실험 결과, 합성된 데이터로 학습한 CQA 모델이 4 개 도메인에서 human-annotation 데이터로 훈련된 모델 대비 F1 점수가 5.4 점 낮은 77.2 점을 달성했으며, 사람이 작성한 데이터와 유사한 분포를 보임을 입증함.

본인 기여도

1 저자. 문제 정의, 관련 연구 탐색, 방법론 설계 및 구현, 실험 및 분석, 논문 작성 등 전 과정을 수행.

초록

Conversational question answering (CQA) facilitates an incremental and interactive understanding of a given context, but building a CQA system is difficult for many domains due to the problem of data scarcity. In this paper, we introduce a novel method to synthesize data for CQA with various question types, including open-ended, closed-ended, and unanswerable questions. We design a different generation flow for each question type and effectively combine them in a single, shared framework. Moreover, we devise a hierarchical answerability classification (hierarchical AC) module that improves quality of the synthetic data while acquiring unanswerable questions. Manual inspections show that synthetic data generated with our framework have characteristics very similar to those of human-generated conversations. Across four domains, CQA systems trained on our synthetic data indeed show good performance close to the systems trained on human-annotated data.

I. 논문

11. Conversational QA Dataset Generation with Answer Revision* (Short Paper)

황선정, 이근배

COLING 2022 (<https://aclanthology.org/2022.coling-1.140>)

연구 목적

도메인 특화 대화형 질의응답(CQA) 시스템 구축에 필요한 대규모 데이터 확보의 비용 문제를 해결하고자 함. 이전 연구의 Conversational QA Generation(CQAG) 프레임워크는 문맥 기반 답변 추출(CAE)과 대화형 질의 생성(CQG)으로 구성된 iterative generation 구조로 이루어져 있어, 초기 답변 추출 단계에서 발생한 오류가 이후 대화 턴의 품질까지 저하시키는 error propagation 문제가 존재함.

접근 방법 및 결과

Pretrained language model(PLM)이 자연스러운 언어 sequence를 생성하도록 학습되었다는 특성에 기반하여, CQG 모델이 질문 생성 직후 교정된 답변을 전달하여 생성하도록 하는 CQG-AR(Answer Revision) 기법을 제안함. 실험 결과, AR 메커니즘이 적용된 CQAG 프레임워크가 합성한 데이터로 훈련된 CQA 모델이 F1 metric에서 기존 방식 대비 13.4 점 향상된 성능을 보여주었음. 또한 Wikipedia 도메인에서 훈련된 모델을 타 도메인에 이식하는 domain adaptation 실험에서도 EM metric 기준 최대 13.1 점의 유의미한 성능 향상을 기록하여 방법론의 범용성을 입증함.

본인 기여도

1 저자. 문제 정의, 관련 연구 탐색, 방법론 설계 및 구현, 실험 및 분석, 논문 작성 등 전 과정을 수행.

초록

Conversational question-answer generation is a task that automatically generates a large-scale conversational question answering dataset based on input passages. In this paper, we introduce a novel framework that extracts question-worthy phrases from a passage and then generates corresponding questions considering previous conversations. In particular, our framework revises the extracted answers after generating questions so that answers exactly match paired questions. Experimental results show that our simple answer revision approach leads to significant improvement in the quality of synthetic data. Moreover, we prove that our framework can be effectively utilized for domain adaptation of conversational question answering.

II. 산학협력 프로젝트

1. Whale UBT 자동 채점 및 자동 출제 시스템 개발을 위한 연구 (2025. 05. – 2025. 12.)

엔에스테블, 네이버

참여 인원: 3 명

프로젝트 목표

네이버와 엔에스테블이 공동으로 개발한 Whale UBT(국가공인자격시험항 버전, K12 버전) 내 탑재될 자동 출제 및 자동 채점 시스템을 위한 사전 연구, 핵심 엔진 구현 및 검증을 최종 목표로 함.

관련 뉴스: “뽕간렌 든 AI... 서술형 답안 채점하고 피드백도 준다” - 동아일보 (<https://n.news.naver.com/mnews/article/020/0003682584?sid=102>)

과업 내용

- 자동 에세이 채점(Automated Essay Scoring: AES) 중 여러 채점 요소를 고려하여 점수를 예측하는 LSTM 기반 모델인 CTS(Cross-prompt Trait Scorer)¹, LoRA 를 이용한 sLLM fine-tuning, 그리고 LLM prompt engineering 기법의 서논술형 자동 채점에 맞게 개선하고 성능을 비교
- 채점 데이터가 확보되기 이전에 자동 채점 모델의 성능을 확인 및 평가할 수 있도록 점수 별 학생 응답을 자동 생성하는 데이터 합성 방법론 연구
- 난이도 조절 기능이 있는 문항 자동 생성 시스템에 대한 선행 연구
- 서논술형 자동 채점 및 피드백 생성 데모 웹 프로그램 제작 및 시현

역할

- 프로젝트 리더
- 데이터 포맷 변환 규격서 작성 및 데이터 전처리
- 난이도 조절 가능한 문항 자동 생성 시스템 연구
 - 교육학 이론과 LLM-judge 를 기반으로 difficulty-calibrated feature constraint sequence 를 구성하는 방법론을 도입함.
 - Multi-dimensional feature constraint 를 만족하는 독해 문항을 생성하는 LLM 기반 multi-agent framework 를 개발함.
 - 관련 논문인 A Multi-Agent Framework for Feature-Constrained Difficulty Control in Reading Comprehension Item Generation 를 ACL 2026 Main Conference 에서 발표할 예정임.
- 학생 답안 및 채점 데이터를 활용하지 않고 채점 기준표 및 출제자 예시 답안만을 활용해 점수 별 예상 학생 답안을 생성할 수 있는 시스템 연구
 - Prompt Engineering 기반의 데이터 합성 플로우를 개발함.
 - 합성 데이터와 LoRA 를 이용해 sLLM 기반 자동 채점 모델을 훈련 및 평가함.

¹ Ridley, Robert, et al. "Automated cross-prompt scoring of essay traits." *Proceedings of the AAAI conference on artificial intelligence*. Vol. 35. No. 15. 2021.

II. 산학협력 프로젝트

2. 문항 유사도 분석 및 한국어능력평가(TOPIK) 자동 생성 알고리즘 연구 (2023. 02. – 2023. 12.)

엔에스데블

참여 인원: 3 명

프로젝트 목표

UBT(Ubiquitous-based test) 클라우드 기반 문제은행 데이터 구조에 최적화된 문항 유사도 분석 알고리즘을 연구하고, 나아가 TOPIK의 대표적인 2개 문항(내용 일치형 문항, 문맥 파악형 문항)을 자동으로 생성하는 AI 모델을 개발하고자 함.

과업 내용

- TOPIK 문제은행의 데이터 구조 분석과 문항 유사도 분석 알고리즘 개발
- 내용 일치형 문항 자동 생성을 위한 AI 기반 시스템 개발
- 문맥 파악형 문항 자동 생성을 위한 AI 기반 시스템 개발

역할

- 내용 일치형 문항 자동 생성을 위한 AI 기반 시스템 개발
 - 다지선다형 내용 일치 문항의 자동 생성을 위한 파이프라인을 설계함.
 - ChatGPT의 prompt engineering으로는 지문에서 사용된 표현 및 통사구조와는 다른 선택지(내용이 일치하거나 일치하지 않는 문장)를 생성하는데 한계가 있었음.
 - 지문으로부터 질의응답 쌍을 생성한 뒤 평서문 형식으로 합치는 방식을 채택함.
 - KorQuAD 데이터를 활용하여 KLUE RoBERTa와 mT5 기반의 질의응답 생성 모델을 fine-tuning 함.

II. 산학협력 프로젝트

3. 고성능 비지도 및 자기지도 대화 시스템 개발 (2022. 04. – 2022. 12.)

삼성리서치 AI 센터

참여 인원: 2 명

프로젝트 목표

목적지향 대화 시스템과 대화형 질의응답 시스템은 모두 사용자 대화 맥락을 파악해 정보를 제공하지만, 고성능 모델 구축을 위한 대용량 훈련 데이터 생성에는 막대한 시간과 비용이 소요됨. 이러한 문제를 해결하기 위해 최소한의 지도 학습만으로도 효율적으로 동작하는 고성능 대화 시스템을 연구함.

과업 내용

- 적은 데이터로 자가 학습이 가능한 목적지향의 대화 시스템 개발
- 자가 데이터 공급 대화형 질의응답 시스템 개발

역할

- 자가 데이터 공급 대화형 질의응답 시스템 개발
 - 문서를 기반으로 대화형 질의응답 시퀀스를 생성하는 CQAG(Conversational Question-Answer Generation) 파이프라인 구축함.
 - 내용 및 형식 측면에서 타당한 질의응답 쌍을 확보하기 위해 Answer Revision 메커니즘을 도입함.
 - 대규모 문서로부터 대화형 질의응답 데이터를 합성 후 질의응답 모델을 훈련시키는 파이프라인 구축함.
 - 관련 논문인 Conversational QA Dataset Generation with Answer Revision 을 COLING 2022 에서 발표함.